

Метрические методы. Метрики качества

10 баллов. +2 бонусных балла

Задача 1. (1 балл)

Оценим время работы алгоритма ближайших соседей по количеству операций. Пусть X — обучающая выборка размера n , Y — тестовая выборка размера m . Размерность признакового пространства d .

Таким образом, $X \in \mathbb{R}^{n \times d}$, а $Y \in \mathbb{R}^{m \times d}$.

Квадрат евклидова расстояния между объектами x_i и y_j записывается как:

$$\rho(x_i, y_j) = \sum_{k=1}^d (x_i^k - y_j^k)^2.$$

- Определите количество операций, необходимое для подсчета всех парных расстояний в наивном случае.
- Предложите способ, с помощью которого можно уменьшить количество операций. Оцените количество операций для предложенного метода.

Решение

Наивный метод

Вычитание - 1 операция, возведение в квадрат - ещё одна операция, всего d слагаемых. То есть на вычисление $\rho(x_i, y_j)$ требуется $2d$ операций. Так как всего mn пар, то количество операций будет равным:

$$N = 2dnm.$$

Ускоренный вариант

Раскроем квадраты:

$$\rho(x_i, y_j)^2 = \sum_{k=1}^d (x_i^k)^2 + \sum_{k=1}^d (y_j^k)^2 - 2 \sum_{k=1}^d x_i^k y_j^k$$

То есть:

$$\rho(x_i, y_j)^2 = \|x_i\|^2 + \|y_j\|^2 - 2(x_i \cdot y_j)$$

Для каждого x_i и y_j квадрат нормы можно вычислить предварительно квадраты норм, это займёт суммарно $(m+n)d$ операций, вычисление скалярного произведения также, как и в наивном варианте, занимает $O(mnd)$ операций, но его можно вычислить как $X^T Y$, что на практике позволяет использовать векторизованные вычисления и ускорить процесс.

Задача 2. (2 балла)

Дано n объектов, распределённых равномерно внутри d -мерного единичного шара с центром в нуле.

- Найдите выражение для медианы расстояния от начала координат до ближайшего объекта.
- Проинтерпретируйте полученный результат в терминах применимости метода ближайшего соседа в различных ситуациях.

Считайте, что метрика в задаче евклидова.

Указание: *попробуйте смоделировать событие и посчитать его вероятность в терминах функций распределения.*

Решение

Нахождения медианы

Объём шара в R^d :

$$V(r) = \frac{\pi^{n/2}}{\Gamma(n/2 + 1)} r^d$$

Так как объекты распределены в шаре радиуса 1 равномерно, то вероятность нахождения объекта внутри шара радиуса $r \in [0; 1]$, являющаяся функцией распределения случайной величины $\rho = \|X\|$ - расстояния от объекта X до центра, равна:

$$\mathbb{P}(X \in B_0(r)) = \frac{V(r)}{V(1)} = r^d = \mathbb{P}(\rho < r) = F_\rho(r)$$

Упорядочим выборку $X_1, \dots, X_n \rightarrow X_{(1)}, \dots, X_{(n)}$ так, чтобы $\rho_{(1)} \leq \rho_{(2)} \leq \dots \leq \rho_{(n)}$.

$$F_{\rho_{(1)}}(r) = \mathbb{P}(\rho_{(1)} \leq r) = 1 - \mathbb{P}(\text{все точки на расстоянии больше } r) = 1 - (1 - r^d)^n$$

Медиана удовлетворяет уравнению $F_{\rho_{(1)}}(m) = 1 - (1 - m^d)^n = \frac{1}{2}$
Отсюда

$$m = (1 - (\frac{1}{2})^{1/n})^{1/d}$$

Интерпретация

Найдём пределы при фиксированных n и d .

$$\lim_{d \rightarrow \infty} m = 1$$

$$\lim_{n \rightarrow \infty} m = 0$$

Получаем, что при большой размерности, все точки будут сконцентрированы у поверхности и будет почти невозможно найти действительно близкого соседа, что демонстрирует проклятье размерности. При этом можно его избежать, но для этого потребуется количество данных, растущее экспоненциально по отношению с d .

Задача 3. (3 балла)

Решается задача классификации с помощью алгоритма ближайших соседей (метрика евклидова). Для тестового объекта z ближайшим соседом с расстоянием ρ_x является x , вторым ближайшим соседом с расстоянием ρ_y является объект y . Остальные объекты обучающей выборки находятся от z на достаточно большом расстоянии.

Ко всем объектам добавляется новый признак: для z и y значение признака распределено равномерно на отрезке $[-1, 1]$, для всех остальных объектов значение признака равно нулю.

- Посчитайте вероятность того, что теперь ближайшим соседом для z будет не x , а y .
- Проинтерпретируйте полученный результат в терминах применимости метода ближайших соседей.

Указание: возможно в этой задаче пригодится знание криволинейных интегралов.

Решение

Нахождение вероятности

Обозначим за ρ'_x и ρ'_y новые расстояния от z до x и y , а через p и q новый признак для z и y соответственно. Тогда

$$(\rho'_x)^2 = \rho_x^2 + p^2$$

$$(\rho'_y)^2 = \rho_y^2 + (p - q)^2$$

Условие того, что новое расстояние до y меньше:

$$\rho_y^2 + (p - q)^2 < \rho_x^2 + p^2$$

$$q^2 - 2pq < \rho_x^2 - \rho_y^2$$

$$2pq - q^2 > \rho_y^2 - \rho_x^2 = D > 0$$

Найдём искомую вероятность $\mathbb{P}(2pq - q^2 > D)$. Знаем, что

$$f_p(x) = f_q(x) = \frac{1}{2} \mathbb{I}\{x \in [-1; 1]\}$$

тогда

$$f_{p,q}(x) = f_p(x)f_q(x) = \frac{1}{4}$$

Найдём $F_\xi(D)$:

$$\mathbb{P}(2pq - q^2 > D) = \iint_{\{(p,q): 2pq - q^2 > D\}} \frac{1}{4} \mathbb{I}\{-1 \leq x \leq 1\} dp dq$$

Задача сводится к тому, чтобы найти площадь пересечения множества (на



картинке закрашено красным, оси в виде (q, p)), по которому происходит интегрирование, и единичного квадрата. Заметим, что если $D > 1$, то пересечение пустое и искомая вероятность равна 0. Найдём точки пересечения графика с квадратом в первой координатной четверти - это $(1 - \sqrt{1-D}; 1)$ и $(1; \frac{D+1}{2})$. Тогда

$$\begin{aligned} \iint_{\{(p,q): 2pq - q^2 > D\}} \frac{1}{4} \mathbb{I}\{-1 \leq x \leq 1\} dp dq &= 2 \cdot \frac{1}{4} \int_{1-\sqrt{1-D}}^1 dq \int_{\frac{q}{2} + \frac{D}{2q}}^1 dp = \int_{1-\sqrt{1-D}}^1 (1 - \frac{q}{2} - \frac{D}{2q}) dq \\ &= \frac{1}{4} (\sqrt{1-D} + 1 - D + D \ln(1 - \sqrt{1-D})) \end{aligned}$$

Подытожим:

$$\mathbb{P}(y \text{ стал ближе } x) = \begin{cases} \frac{1}{4}(\sqrt{1 - (\rho_y^2 - \rho_x^2)} + 1 - (\rho_y^2 - \rho_x^2)(1 - \ln(1 - \sqrt{1 - (\rho_y^2 - \rho_x^2)}))), \rho_y^2 - \rho_x^2 \leq 1 \\ 0, (\rho_y^2 - \rho_x^2) > 1 \end{cases}$$

Интерпретация

Порядок ближайших соседей может быть изменён даже из-за случайного признака, поэтому для данного метода важен отбор наиболее релевантных признаков.

Задача 4. (1 балл)

Докажите, что ROC-AUC случайного классификатора равен 0.5.

Решение

Ясно, что при случайной классификации, вероятности TP, TN, FP и FN одинаковы и равны (TPR и FPR также будут равны), так как ROC-AUC - это площадь под графиком $TPR(FPR)$, который в данном случае представляет собой диагональ единичного квадрата, то значение этой метрики будет равно $\frac{1}{2}$.

Задача 5. (2 балла)

Пусть, $a = a(x)$ ответ алгоритма. На сколько может уменьшиться ROC-AUC при использовании функции $\min(a, 0.5)$ над оценками алгоритма?

Решение

Все объекты с оценками $> 0,5$ получают оценку 0,5, а оценка объектов с исходной $\leq 0,5$ не изменится. ROC-AUC можно интерпретировать как вероятность того, что случайный положительный объект будет оценён выше, чем случайный отрицательный.

Приведём пример для изменения на 0,5:

Пусть всех положительных объекты имеют оценки, больше 0,5, а отрицательные - 0,5, тогда изначально ROC-AUC = 1, после преобразования все объекты имеют одинаковые метки и ROC-AUC = 0,5.

Заметим, что если изначально ROC-AUC $\leq 0,5$, то он точно не сможет вырасти, так как количество пар, в которых у положительного объекта оценка будет выше, чем у отрицательного не увеличится. Если же $0,5 < \text{ROC-AUC} < 1$, то после преобразования ROC-AUC не может стать меньше 0,5, так как соотношения между оценками TP и TN, а так же FP и FN не изменятся, а у всех TP и FP будут одинаковые метки. Значит в таком случае ROC-AUC изменится меньше, чем на 0,5.

Ответ: 0,5.

Задача 6. (3 балла)

Подробнее ознакомьтесь с материалом по ROC-AUC по ссылке и решите следующую задачу:

Пусть на ответах алгоритма m (принимающих значения от 0 до 1) задано распределение объектов класса 1 (доля объектов класса 1 в зависимости от ответа алгоритма) следующим образом:

$$\mathbb{P}(m \in [a, b] \mid y = 1) = \int_a^b p(z) dz.$$

Распределение объектов класса 0 задаётся так:

$$\mathbb{P}(m \in [a, b] \mid y = 0) = \int_a^b (2 - p(z)) dz,$$

где $p(z) = -1.5z^2 + 3z$.

Найдите вероятностные оценки на величины TPR, FPR и ROC-AUC.

Решение

$$TPR(x) = \mathbb{P}(m > x \mid y = 1) = \int_x^1 (-1.5z^2 + 3z) dz = 0.5x^3 - 1.5x^2 + 1.$$

$$FPR(x) = \mathbb{P}(m > x \mid y = 0) = \int_x^1 (2 + 1.5z^3 - 3z) dz = -0.5x^3 + 1.5x^2 - 2x + 1,$$

$$ROC-AUC = \int_1^0 TPR(x) FPR'(x) dx = \int_0^1 (0.5x^3 - 1.5x^2 + 1)(1.5x^2 - 3x + 2) dx = 0.75$$